

Notatki do wykładu Metody Numeryczne 1

Iwona Wróbel, 28.03.2025r.

Na podstawie notatek dr. Adama Grabarskiego, dr. Pawła Kellera, własnych notatek oraz innych źródeł.

Ważne: Notatki te zawierają część zagadnień omawianych na wykładzie z Metod Numerycznych 1.

Notatki są chronione prawem autorskim. Osoby zapisane na przedmiot mogą ich używać i przechowywać przez dowolnie długi czas, jednak zabronione jest ich udostępnianie w jakikolwiek sposób (przez media społecznościowe, strony internetowe, pocztę elektroniczną itp.).

Zmiany w stosunku do wcześniejszych wersji:

- dodane rozdziały 2 i 3 (14.03.2025r.),
- dokończony rozdział 3 (dodane podrozdziały 3.5 i 3.6), dodany rozdział 4 (28.03.2025r.).

Spis treści

1	Błędy w obliczeniach numerycznych	4
1.1	Błąd bezwzględny i błąd względny	4
1.2	Uwarunkowanie zadania numerycznego	4
1.2.1	Błąd wartości funkcji	4
1.3	Błędy działań arytmetycznych	8
1.3.1	Dodawanie i odejmowanie	8
1.3.2	Mnożenie	8
1.3.3	Dzielenie	9
1.4	Reprezentacja maszynowa liczb zmiennoprzecinkowych	9
1.5	Własności podstawowych operacji arytmetycznych	10
1.6	Elementy rachunku błędów	10
1.7	Problem utraty cyfr znaczących	11
1.8	Numeryczna poprawność algorytmów	12
1.8.1	Oszacowanie błędu algorytmu numerycznie poprawnego	13
2	Obliczanie wartości wielomianu i jego pochodnych	14
2.1	Schemat Hornera	14
2.2	Obliczanie wartości pochodnej wielomianu	15
2.3	Obliczanie wartości drugiej pochodnej wielomianu	16

3	Interpolacja	18
3.1	Interpolacja wielomianowa	18
3.2	Postać Lagrange’a wielomianu interpolacyjnego	18
3.3	Postać Newtona wielomianu interpolacyjnego, schemat ilorazów różnicowych	20
3.4	Uogólniony schemat Hornera	22
3.5	Błąd interpolacji, zbieżność procesów interpolacyjnych, dobór węzłów . . .	23
3.5.1	Zbieżność procesów interpolacyjnych. Zjawisko Rungego	25
3.6	Interpolacja Hermite’a	26
4	Całkowanie numeryczne	31
4.1	Kwadratury	31
4.2	Kwadratury interpolacyjne	32
4.3	Kwadratury Newtona-Cotesa (proste)	33
4.3.1	Kwadratura (wzór) trapezów (prosta)	34
4.3.2	Kwadratura (wzór) Simpsona (prosta)	34
4.3.3	Kwadratura (wzór) Newtona 3/8 (prosta)	35
4.3.4	Kwadratura prostokątów (prosta)	35
4.4	Kwadratury złożone	36
4.4.1	Złożona kwadratura trapezów	37
4.4.2	Złożona kwadratura Simpsona	37
4.4.3	Złożona kwadratura prostokątów	38
4.4.4	Złożona kwadratura Newtona	38
4.5	Zmiana przedziału całkowania	39
4.6	Metoda Romberga	39
	Literatura	42

1 Błędy w obliczeniach numerycznych

Błędy, ze względu na źródło ich powstawania, możemy podzielić na:

- błędy pomiarów (błędy danych zadania) – nimi się nie będziemy zajmować,
- błędy zaokrągleń,
- błędy metod.

1.1 Błąd bezwzględny i błąd względny

Wprowadźmy oznaczenia:

$x \in \mathbb{R}$ – wartość dana dokładnie,

$\tilde{x} \in \mathbb{R}$ – przybliżenie x .

błąd bezwzględny: $\Delta = \tilde{x} - x$,

błąd względny (dla $x \neq 0$): $\delta = \frac{\tilde{x}-x}{x} = \frac{\Delta}{x}$,

Z określenia tych błędów wynika, że

$$\tilde{x} = x + \Delta, \quad \tilde{x} = x(1 + \delta).$$

Najczęściej nie znamy dokładnych wartości błędu bezwzględnego i względnego. W praktyce korzystamy z oszacowań tych błędów:

$$|\Delta| \leq \varepsilon, \quad |\delta| \leq \varepsilon.$$

1.2 Uwarunkowanie zadania numerycznego

Zadanie numeryczne to problem obliczeniowy, w którym dane (argumenty wejściowe) i wyniki (argumenty wyjściowe) są liczbami. Ogólnie, zadanie numeryczne to funkcja $\varphi : D \rightarrow W$, gdzie

$D \in \mathbb{R}^n$ – zbiór możliwych danych dla zadania numerycznego φ ,

$W \in \mathbb{R}^m$ – zbiór możliwych wyników dla zadania numerycznego φ .

1.2.1 Błąd wartości funkcji

Spróbujmy ocenić w przybliżeniu błąd bezwzględny i błąd względny, jaki popełniamy, obliczając wartość funkcji

$$y = f(x),$$

gdzie $f : \mathbb{R} \rightarrow \mathbb{R}$. Założymy przy tym, że przyjęty do obliczeń argument x jest dany niedokładnie, a oszacowanie błędu δ jest niewielkie.

Założmy, że funkcja f ma ciągle pochodne do rzędu drugiego włącznie na pewnym otoczeniu punktu x oraz $\tilde{x} = x(1 + \delta) = x + \delta x$ jest punktem z tego otoczenia. Wtedy, korzystając z rozwinięcia f w szereg Taylora, możemy zapisać

$$f(\tilde{x}) = f(x) + f'(x)(\tilde{x} - x) + \frac{1}{2}f''(\xi)(\tilde{x} - x)^2,$$

dla pewnego ξ , przy czym $\xi \in (x, \tilde{x})$, jeśli $x < \tilde{x}$ lub $\xi \in (\tilde{x}, x)$, jeśli $\tilde{x} < x$.

Stąd

$$f(\tilde{x}) - f(x) = f'(x)(\tilde{x} - x) + \frac{1}{2}f''(\xi)(\tilde{x} - x)^2.$$

Dla dostatecznie małego $(\tilde{x} - x)$ wartość $(\tilde{x} - x)^2$ jest dużo mniejsza niż $(\tilde{x} - x)$, można zatem przyjąć, że

$$f(\tilde{x}) - f(x) \approx f'(x)(\tilde{x} - x).$$

Stąd, jeśli $f(x) \neq 0$, mamy

$$\frac{|f(\tilde{x}) - f(x)|}{|f(x)|} \approx \frac{|f'(x)|}{|f(x)|}|\tilde{x} - x| = \frac{|f'(x)|}{|f(x)|}|\delta x| = \frac{|xf'(x)|}{|f(x)|}|\delta|.$$

Pomińmy środkowe fragmenty powyższego przekształcenia i zapiszmy ponownie zależność, którą otrzymaliśmy:

$$\frac{|f(\tilde{x}) - f(x)|}{|f(x)|} \approx \frac{|xf'(x)|}{|f(x)|}|\delta|.$$

Po lewej stronie mamy błąd względny wartości funkcji (czyli wyniku obliczeń), a po prawej błąd względny argumentu przemnożony przez wielkość $\frac{|xf'(x)|}{|f(x)|}$. Wielkość ta jest zatem mnożnikiem, z jakim błąd danych przenosi się na wynik. Oznaczana jest przez $c(x)$ i nazywana wskaźnikiem uwarunkowania obliczania wartości funkcji f . Mamy zatem:

$$c(x) = \frac{|xf'(x)|}{|f(x)|}. \quad (1.1)$$

Wskaźnik uwarunkowania zależy zarówno od funkcji (ogólniej: od zadania obliczeniowego), jak i argumentu x (czyli danych wejściowych zadania). Dla pewnych funkcji może nie zależeć od x , ale to są szczególne przypadki.

Wskaźnik uwarunkowania mierzy wpływ błędu względnego danych wejściowych na błąd wyniku.

Mówimy, że zadanie numeryczne jest dobrze uwarunkowane, jeśli niewielka zmiana danych wejściowych powoduje niewielką zmianę wyniku (niewielki błąd w danych nie zmieni wyniku w sposób znaczący). W przeciwnym wypadku zadanie jest źle uwarunkowane.

Uwaga 1.1. *Nie ma ścisłej granicy (konkretnej wartości wskaźnika uwarunkowania), przy której kończy się dobre uwarunkowanie, a zaczyna złe. Im wskaźnik uwarunkowania mniejszy, tym zadanie jest lepiej uwarunkowane.*

Ponieważ uwarunkowanie rozważa się w kontekście obliczeń numerycznych, gdzie bierze się pod uwagę błędy (danych oraz wyniku) wynikające z zaokrągleń, a większość systemów obliczeniowych korzysta z arytmetyki podwójnej precyzji, gdzie błąd pojedynczego zaokrąglenia jest rzędu $1e-16$ (czyli 10^{-16}), najczęściej przyjmuje się, że jeśli wskaźnik uwarunkowania nie przekracza 100, a nawet 1000, to zadanie jest dobrze uwarunkowane.

Przykład 1.1.

Zbadaj uwarunkowanie obliczania wartości funkcji $f(x) = x^2 - 1$, $x \in \mathbb{R}$?

Rozwiązanie:

Funkcja $f(x) = x^2 - 1$ jest różniczkowalna, zatem możemy skorzystać ze wzoru (1.1). Po podstawieniu otrzymujemy

$$C(x) = \left| \frac{2x^2}{x^2 - 1} \right|.$$

Wskaźnik uwarunkowania $C(x)$ jest duży dla x bliskiego 1 lub -1. Oznacza to, że dla $x \approx 1$ lub $x \approx -1$ małe względne zaburzenie danych wejściowych (czyli argumentu x) może powodować duży błąd względny wyniku (czyli obliczonej wartości $f(x)$). Zatem dla argumentów bliskich 1 lub -1 zadanie obliczania wartości funkcji f jest źle uwarunkowane. Dla x dalekich od zera wskaźnik uwarunkowania jest mały ($\lim_{x \rightarrow \pm\infty} C(x) = 2$), zatem dla argumentów o dużym module uwarunkowanie jest dobre.

Ważne! Uwarunkowanie jest własnością problemu obliczeniowego. Nie jest związane z algorytmem (sposobem), jakim ten problem rozwiązujemy. W przypadku obliczania wartości funkcji, sposób zapisania wzoru tej funkcji nie wpływa na uwarunkowanie. Na przykład, funkcję z powyższego przykładu można zapisać jako $f(x) = x^2 - 1$ lub $f(x) = (x - 1)(x + 1)$ (lub jeszcze inaczej). Uwarunkowanie pozostaje takie samo.

Przykład 1.2.

Zbadaj uwarunkowanie obliczania wartości funkcji $f(x) = x^2 + 1$, $x \in \mathbb{R}$?

Rozwiązanie:

Postępując podobnie, jak w Przykładzie 1, otrzymujemy

$$C(x) = \left| \frac{2x^2}{x^2 + 1} \right| = 2 \left| \frac{x^2 + 1}{x^2 + 1} - \frac{1}{x^2 + 1} \right| = 2 \left| 1 - \frac{1}{x^2 + 1} \right| < 2.$$

Wskaźnik uwarunkowania jest ograniczony i nie przekracza 2, niezależnie od wartości x . Zatem zadanie obliczania wartości funkcji f jest dobrze uwarunkowane dla każdego argumentu x .

Uwarunkowanie obliczania wartości funkcji wielu zmiennych bada się podobnie jak w przypadku funkcji jednej zmiennej, z tym, że rozważamy częściowe wskaźniki uwarunkowania, ze względu na każdą ze zmiennych.

Niech $f : \mathbb{R}^2 \rightarrow \mathbb{R}$, czyli $f = f(x_1, x_2)$. Mamy wtedy dwa częściowe wskaźniki uwarunkowania

$$c_1(x_1, x_2) = \frac{|x_1 \frac{\partial f}{\partial x_1}(x_1, x_2)|}{|f(x_1, x_2)|}, \quad c_2(x_1, x_2) = \frac{|x_2 \frac{\partial f}{\partial x_2}(x_1, x_2)|}{|f(x_1, x_2)|}, \quad (1.2)$$

gdzie $\frac{\partial f}{\partial x_k}(x_1, x_2)$ oznacza pochodną cząstkową funkcji f względem zmiennej x_k , $k = 1, 2$. O uwarunkowaniu obliczania wartości funkcji f świadczą oba te wskaźniki, zatem łączny wskaźnik uwarunkowania można zdefiniować jako ich sumę

$$C(x_1, x_2) = c_1(x_1, x_2) + c_2(x_1, x_2).$$

Formalnie można powyższe wzory uzasadnić korzystając z rozwinięcia Taylora funkcji wielu zmiennych.

W przypadku funkcji większej liczby zmiennych wzory są analogiczne.

Przykład 1.3.

Zbadaj uwarunkowanie obliczania wartości funkcji

$$f(x_1, x_2) = x_1^2 + x_2, \quad (x_1, x_2) \in \mathbb{R}^2?$$

Rozwiązanie:

Obliczamy wskaźniki uwarunkowania ze względu na każdą ze zmiennych, korzystając ze wzorów (1.2). Otrzymujemy:

$$c_1(x_1, x_2) = \left| \frac{2x_1^2}{x_1^2 + x_2} \right|, \quad c_2(x_1, x_2) = \left| \frac{x_2}{x_1^2 + x_2} \right|,$$

a następnie:

$$C(x_1, x_2) = \frac{2x_1^2 + |x_2|}{|x_1^2 + x_2|}.$$

Wskaźnik uwarunkowania jest duży, gdy $x_1^2 \approx -x_2$. Zatem dla takich argumentów zadanie obliczania wartości funkcji f jest źle uwarunkowane. Natomiast, gdy wartość $|x_1^2 + x_2|$ nie jest zbyt bliska 0, uwarunkowanie jest dobre. W szczególności, dla $x_2 > 0$,

$$C(x_1, x_2) = \frac{2x_1^2 + x_2}{x_1^2 + x_2} < \frac{2x_1^2 + 2x_2}{x_1^2 + x_2} = 2,$$

z czego wynika, że błąd względny wyniku (obliczonej wartości funkcji f) będzie co najwyżej 2 razy większy niż błąd względny argumentów.

W przypadku, gdy $f : \mathbb{R}^n \rightarrow \mathbb{R}$, gdzie $n > 2$, wskaźnik uwarunkowania oblicza się analogicznie jak w przypadku $f : \mathbb{R}^2 \rightarrow \mathbb{R}$. W przypadku innych zadań numerycznych $\varphi : \mathbb{R}^n \rightarrow \mathbb{R}^m$, gdzie $n, m \geq 1$, zbadanie uwarunkowania może być bardziej skomplikowane.

1.3 Błędy działań arytmetycznych

1.3.1 Dodawanie i odejmowanie

Dodawanie lub odejmowanie można wyrazić za pomocą funkcji $f(x_1, x_2) = x_1 + x_2$, gdzie $x_1, x_2 \in \mathbb{R}$. Będziemy rozważać błąd względny wartości tej funkcji, zatem założymy, że $x_1 + x_2 \neq 0$. Niech $\tilde{x}_i = x_i(1 + \delta_i)$, $|\delta_i| \leq \varepsilon$ dla $i = 1, 2$. Mamy

$$\begin{aligned} \left| \frac{f(x_1, x_2) - f(\tilde{x}_1, \tilde{x}_2)}{f(x_1, x_2)} \right| &= \left| \frac{x_1 + x_2 - \tilde{x}_1 - \tilde{x}_2}{x_1 + x_2} \right| = \left| \frac{x_1 + x_2 - x_1(1 + \delta_1) - x_2(1 + \delta_2)}{x_1 + x_2} \right| = \\ &= \left| \frac{x_1 + x_2 - x_1 - x_1\delta_1 - x_2 - x_2\delta_2}{x_1 + x_2} \right| = \left| \frac{x_1\delta_1 + x_2\delta_2}{x_1 + x_2} \right| = \\ &= \left| \delta_1 \frac{x_1}{x_1 + x_2} + \delta_2 \frac{x_2}{x_1 + x_2} \right| \leq |\delta_1| \left| \frac{x_1}{x_1 + x_2} \right| + |\delta_2| \left| \frac{x_2}{x_1 + x_2} \right| \leq \\ &\leq \frac{|x_1| + |x_2|}{|x_1 + x_2|} \varepsilon. \end{aligned}$$

Jeśli $|x_1 + x_2|$ ma małą wartość w stosunku do $|x_1|$ i $|x_2|$, to błąd względny wyniku może być bardzo duży, nawet jeśli błąd danych (czyli δ_1 i δ_2) jest niewielki. Zatem, gdy $x_1 \approx -x_2$, błąd może się bardzo wzmocnić.

Odejmowanie bliskich liczb jest operacją, która może być źródłem dużych błędów.

Jeśli x_1 i x_2 są tego samego znaku, to $\frac{|x_1| + |x_2|}{|x_1 + x_2|} = 1$, i w konsekwencji

$$\left| \frac{f(x_1, x_2) - f(\tilde{x}_1, \tilde{x}_2)}{f(x_1, x_2)} \right| \leq \varepsilon,$$

co oznacza, że błąd względny wyniku jest na poziomie błędu względnego danych. (To bardzo dobrze – operacja nie powoduje wzmocnienia błędu.)

Do podobnych wniosków można dojść obliczając wskaźnik uwarunkowania z wykorzystaniem wzorów podanych podrozdziale 1.2.

1.3.2 Mnożenie

Mnożenie można wyrazić za pomocą funkcji $f(x_1, x_2) = x_1 x_2$, gdzie $x_1, x_2 \in \mathbb{R}$. Założymy, analogicznie jak poprzednio, że $x_1 x_2 \neq 0$. Ponownie, niech $\tilde{x}_i = x_i(1 + \delta_i)$, $|\delta_i| \leq \varepsilon$ dla $i = 1, 2$. Mamy

$$\begin{aligned} \left| \frac{f(x_1, x_2) - f(\tilde{x}_1, \tilde{x}_2)}{f(x_1, x_2)} \right| &= \left| \frac{x_1 x_2 - \tilde{x}_1 \tilde{x}_2}{x_1 x_2} \right| = \left| \frac{x_1 x_2 - x_1(1 + \delta_1)x_2(1 + \delta_2)}{x_1 x_2} \right| = \\ &= |1 - (1 + \delta_1)(1 + \delta_2)| = |\delta_1 + \delta_2 + \delta_1 \delta_2| \approx |\delta_1 + \delta_2| \leq \\ &\leq 2\varepsilon. \end{aligned}$$

Błąd względny wyniku zależy od błędów argumentów i jest co najwyżej 2 razy większy od maksymalnego z tych błędów. Nie zależy natomiast od samych argumentów, co jest bardzo wygodną własnością.

1.3.3 Dzielenie

Do uzupełnienia samodzielnie.

Wskazówka: można skorzystać z tego, że $(1 + \delta)(1 - \delta) = 1 - \delta^2 \approx 1$, a zatem $\frac{1}{1 + \delta} \approx 1 - \delta$. (To przybliżenie jest prawdziwe dla małych wartości $|\delta|$, a tutaj mamy właśnie taki przypadek).

1.4 Reprezentacja maszynowa liczb zmiennoprzecinkowych

Twierdzenie 1.1. *Każda liczba rzeczywista $x \neq 0$ posiada jednoznaczne przedstawienie*

$$x = sm2^c,$$

gdzie $s \in \{-1, 1\}$, $1 \leq m < 2$, a $c \in \mathbb{Z}$ (c jest liczbą całkowitą).

Mantysę m można zapisać jako

$$m = \sum_{i=0}^{\infty} d_i 2^{-i}, \quad (1.3)$$

gdzie $d_i \in \{0, 1\}$ dla wszystkich $i = 0, 1, \dots$. Liczba bitów przeznaczona na zapisanie mantysy w pamięci komputera jest skończona, zatem zachodzi konieczność zaokrąglenia. Oznaczmy tę liczbę przez t , a przez m_t mantysę zaokrągloną do $t + 1$ bitów. Zaokrągloną mantysę można zapisać jako

$$m_t = \sum_{i=0}^t d_i 2^{-i} + d_{t+1} 2^{-t}, \quad (1.4)$$

Zauważmy, że z warunku $1 \leq m < 2$ wynika, że $d_0 = 1$ w (1.3), co oznacza, że nie ma konieczności przechowywania wiodącego bitu m_t . Zatem do przechowania zaokrąglonej mantysy m_t wystarcza t bitów.

Liczba rzeczywista $x \neq 0$ przechowywana jest w pamięci komputera jako

$$\text{rd}(x) = sm_t 2^c. \quad (1.5)$$

Można pokazać, że $|m_t - m| \leq 2^{-t-1}$ oraz, że

$$\text{rd}(x) = x(1 + \delta),$$

gdzie δ jest błędem względnym reprezentacji, przy czym $|\delta| \leq 2^{-t-1}$. Liczba $u = 2^{-t-1}$ jest zatem ograniczeniem górnym na błąd pojedynczego zaokrąglenia (ang. *unit round-off error*). Wartość $\varepsilon_M = 2^{-t}$ nazywana jest *precyzją obliczeń*. Liczba $1 + \varepsilon_M$ jest najmniejszą liczbą maszynową większą niż 1. *Liczba maszynowa* to liczba, która posiada dokładną reprezentację (w danej arytmetyce), tj. x jest liczbą maszynową, jeśli $x = \text{rd}(x)$.

Uwaga 1.2. *Wzór (1.4) jest wykorzystywany w rozważaniach teoretycznych. W praktyce w procesorach zaokrąglenia mogą się odbywać nieco inaczej:*

- jeśli $m = \sum_{i=0}^t d_i 2^{-i} + 2^{-t-1}$, to oba zaokrąglenia (w górę i w dół),

$$m_t = \sum_{i=0}^t d_i 2^{-i} + 2^{-t} \quad i \quad \widehat{m}_t = \sum_{i=0}^t d_i 2^{-i},$$

są równie dobre ($|m_t - m| = |\widehat{m}_t - m| = 2^{-t-1}$). Według standardu IEEE 754 należy wybrać to z powyższych zaokrągleń, w którym najmniej znaczący bit jest równy 0.

- jeśli $m = \sum_{i=0}^{t+1} 2^{-i} + \sum_{i=t+2}^{\infty} d_i 2^{-i}$, to z (1.4) wynika, że $m_t = 2$. W komputerze m_t otrzymuje wtedy wartość 1, a wykładnik c w (1.5) jest zwiększany o 1.

1.5 Własności podstawowych operacji arytmetycznych

Niech $\text{fl}(\text{wyrażenie})$ oznacza wartość *wyrażenia* obliczoną za pomocą komputera. Arytmetyka większości procesorów ma tę własność, że jeśli $x = \text{rd}(x)$ oraz $y = \text{rd}(y)$ (czyli x i y są dokładnie reprezentowane), to $\text{fl}(x \bullet y) = \text{rd}(x \bullet y)$, gdzie $\bullet$ oznacza jedną (dowolną) z czterech podstawowych operacji arytmetycznych: $+$, $-$, $*$, $/$. Podobnie, zachodzi też $\text{fl}(\sqrt{x}) = \text{rd}(\sqrt{x})$. Oznacza to, że błąd arytmetyki jest taki jak błąd reprezentacji wyniku (porównaj podrozdział 1.6).

1.6 Elementy rachunku błędów

W analizie algorytmów bada się, jaki wpływ na wynik mają błędy względne argumentów oraz błędy generowane przez działania arytmetyczne.

Notacja $\tilde{x} = x(1 + \delta)$ jest bardzo wygodna w analizie błędów. Zbadajmy dla przykładu przenoszenie błędów przy obliczaniu iloczynu trzech liczb: $\text{fl}(xyz)$. Przyjmijmy dla uproszczenia, że dane są reprezentowane dokładnie. Mamy

$$\begin{aligned} \text{fl}(xyz) &= (xy(1 + \delta_1)z)(1 + \delta_2) = xyz(1 + \delta_1)(1 + \delta_2) \\ &= xyz(1 + \delta_1 + \delta_2 + \delta_1\delta_2). \end{aligned}$$

Błąd δ_1 jest błędem mnożenia x przez y , a błąd δ_2 jest błędem mnożenia otrzymanego wyniku mnożenia x przez y przez z . Każde działanie jest źródłem błędu.

Jeśli $|\delta_1|, |\delta_2| \leq u$, to

$$\text{fl}(xyz) = xyz(1 + \delta),$$

gdzie $|\delta| \leq 2u + \mathcal{O}(u^2)$. Zauważmy, że u^2 jest dużo mniejsze niż u . (Na przykład, jaka jest wartość u , gdy $t = 52$, czyli przy podwójnej precyzji?) Zatem błąd otrzymanego wyniku jest zawsze bardzo mały.

Czasem, dla uproszczenia rachunku błędów tego typu, pomija się iloczyny dwóch lub więcej błędów. (Można tak będzie zrobić w jednym z zadań na liście C.)

Uwaga 1.3. W zbiorze liczb rzeczywistych zachodzą prawa łączności, przemienności i rozdzielności. W zbiorze liczb maszynowych mamy wyłącznie przemienność dodawania i odejmowania (porównaj przykład 1.4). Wynika stąd, że algorytmy matematycznie równoważne mogą dawać istotnie różne wyniki.

1.7 Problem utraty cyfr znaczących

Z własności operacji arytmetycznych opisanych w podrozdziale 1.5 nie wynika, że wszystkie obliczenia wykonywane na komputerze są dokładne. Załóżmy, że x i y nie są liczbami maszynowymi. Wtedy,

$$\begin{aligned}\text{fl}(x + y) &= \text{fl}(\text{rd}(x) + \text{rd}(y)) = (x(1 + \delta_1) + y(1 + \delta_2))(1 + \delta_3) \\ &= x + y + x(\delta_1 + \delta_3) + y(\delta_2 + \delta_3) + x\delta_1\delta_3 + y\delta_2\delta_3,\end{aligned}$$

gdzie $|\delta_1|, |\delta_2|, |\delta_3| < u$. Jeśli $|\delta_1 - \delta_2| \approx 2u$, to (w pewnym sensie)

$$\lim_{x \rightarrow -y} \frac{|\text{fl}(x + y) - (x + y)|}{|x + y|} \approx \lim_{x \rightarrow -y} \frac{|2xu|}{|x + y|} = \infty.$$

Problem utraty cyfr znaczących pojawia się przy dodawaniu lub odejmowaniu (dwóch lub więcej) składników, przy czym oczekiwany (dokładny) wynik tego działania jest dużo mniejszy niż składniki. Jeśli przez T oznaczymy największy (co do modułu) składnik, a przez R dokładny (prawdziwy) wynik, to – z grubsza – można oczekiwać, że błąd względny wyniku jest w przybliżeniu $|R|^{-1}|T|$ razy większy niż błąd względny argumentów.

Przykład 1.4. Przykład ten pochodzi z pozycji [9].

Rozważmy liczby, które można zapisać w systemie dziesiętnym w postaci $x = sm_5 10^{c_1}$, tj. na zapisanie mantysy mamy 5 bitów, a na zapisanie cechy 1 bit. Znak liczby jest zapisywany na dodatkowym bicie.

W przykładzie tym podstawą jest 10, a nie 2, dla większej czytelności wyników.

Rozważmy działanie

$$0.98765 + 0.012424 - 0.0065432,$$

którego dokładnym wynikiem jest 0.9935308. Ponieważ do zapisania mantysy mamy tylko 5 bitów, zapamiętane mogą być tylko podkreślone cyfry. Zaokrąglenie odbywa się w standardowy sposób.

Sprawdźmy, jaki wpływ ma kolejność działań na wynik. Operacje wykonywane w obecności błędów zaokrągleń są wzięte w kółko. Każda z tych operacji obciążona jest błędem (wynik każdej operacji jest zaokrąglany, zanim zostanie przekazany do dalszych obliczeń). Wykonując powyższe działanie na trzech liczbach możemy postawić nawiasy na dwa sposoby.

Mamy:

$$\begin{aligned}0.98765 \oplus (0.012424 \ominus 0.0065432) &= \\0.98765 \oplus 0.00588(08) &= 0.99353(08), \\(0.98765 \oplus 0.012424) \ominus 0.0065432 &= \\1.000074 (\approx 1.0001) \ominus 0.0065432 &= 0.99356.\end{aligned}$$

Pierwszy wynik jest dokładny (na tyle, na ile to możliwe przy 5-bitowej mantysie). Drugi wynik już nie. Błąd nie jest bardzo duży (różnica występuje na ostatniej cyfrze), ale widać, że kolejność wykonywania działań ma znaczenie.

Zbadajmy teraz rozdzielną mnożenia względem odejmowania. Rozważmy działanie

$$(4.2832 - 4.2821) * 5.7632,$$

którego dokładnym wynikiem jest 0.00633952. Wykonując obliczenia na komputerze (i zaokrąglając pośrednie wyniki), otrzymamy:

$$\begin{aligned}(4.2832 \ominus 4.2821) \otimes 5.7632 &= \\0.0011 \otimes 5.7632 &= 0.0063395(2), \\(4.2832 \otimes 5.7632) \ominus (4.2821 \otimes 5.7632) &= \\24.684(93824) (\approx 24.685) \ominus 24.678(59872) (\approx 24.679) &= 0.0060000.\end{aligned}$$

Przy obliczeniach za pomocą drugiego algorytmu można zaobserwować dużą utratę cyfr znaczących. Uzyskany wynik zawiera tylko jedną poprawną cyfrę. W ostatnim działaniu odejmowane są bliskie liczby, wynik zależy więc od ostatnich bitów. A te zostały utracone przy wcześniejszych obliczeniach.

W najczęściej stosowanych arytmetykach jest więcej bitów na zapisanie cechy i mantysy, niemniej schemat (i wynikające z niego problemy) jest podobny.

Przykład 1.5. Ciekawe wyniki można uzyskać wykonując w arytmetyce podwójnej precyzji obliczenia z zadania K8 (rozdział 2.2) z pozycji [1]. Warto samodzielnie zaimplementować oba sposoby obliczenia wartości podanej tam funkcji, np. w środowisku Matlab, Octave, C, R, itp.

1.8 Numeryczna poprawność algorytmów

Oznaczenia:

$D \in \mathbb{R}^n$ – zbiór możliwych danych dla zadania numerycznego φ ,

$W \in \mathbb{R}^m$ – zbiór możliwych wyników dla zadania numerycznego φ ,

$\varphi : D \rightarrow W$ – zadanie numeryczne.

Definicja 1.1. Algorytm A dla zadania numerycznego φ nazywamy numerycznie poprawnym, jeśli istnieje stała K , niezależna od wskaźnika uwarunkowania ($C(d)$) i arytmetyki (t) taka, że dla dowolnej danej $d \in D$ istnieje dana $\tilde{d} \in D$ taka, że

$$\|\tilde{d} - d\| \leq K 2^{-t} \|d\| \quad (1.6)$$

oraz

$$fl(A(d)) = \varphi(\tilde{d}). \quad (1.7)$$

Innymi słowy, wynik algorytmu A dla danej d (dokładnej) uzyskany w arytmetyce fl jest dokładnym wynikiem zadania φ dla "nieco" zaburzonej danej $\tilde{d}$.

1.8.1 Oszacowanie błędu algorytmu numerycznie poprawnego

Załóżmy, że algorytm A dla zadania φ jest numerycznie poprawny. Rozpatrując normę różnicy między wynikiem otrzymanym algorytmem A w arytmetyce fl a wynikiem dokładnym otrzymamy:

$$\begin{aligned} \|fl(A(d)) - \varphi(d)\| &= \|\varphi(\tilde{d}) - \varphi(d)\| \leq C(d) \frac{\|\tilde{d} - d\|}{\|d\|} \|\varphi(d)\| \\ &\leq K 2^{-t} C(d) \|\varphi(d)\|. \end{aligned}$$

(Pierwsza z powyższych nierówności wynika z definicji wskaźnika uwarunkowania.)
Zatem

$$\frac{\|fl(A(d)) - \varphi(d)\|}{\|\varphi(d)\|} \leq K 2^{-t} C(d). \quad (1.8)$$

(Zakładamy, że $\|\varphi(d)\| \neq 0$ i $\|d\| \neq 0$; w przeciwnym razie nie ma sensu rozpatrywać błędów względnych.)

Uwaga 1.4. Oszacowanie (1.8) zależy od wskaźnika uwarunkowania, zatem, jeśli zadanie jest źle uwarunkowane, wynik może być niedokładny, nawet jeśli stosujemy algorytm numerycznie poprawny.

Uwaga 1.5. Przy $t \rightarrow \infty$ błąd dąży do zera; ze wzrostem dokładności arytmetyki błąd jest coraz mniejszy.

2 Obliczanie wartości wielomianu i jego pochodnych

Niech

$$f(x) = a_0 + a_1x + \dots + a_{n-1}x^{n-1} + a_nx^n, \quad (2.1)$$

gdzie $a_k \in \mathbb{R}$, dla $k = 1, \dots, n$.

Naszym celem będzie obliczenie wartości $f(\hat{x})$, gdzie $\hat{x} \in \mathbb{R}$ jest dany.

Można to zrobić na wiele sposobów.

Najprościej jest po prostu podstawić $\hat{x}$ do wzoru (2.1) i wykonać potrzebne obliczenia.

Koszt takiego podejścia, liczony liczbą operacji arytmetycznych, to około $2n$ mnożeń i n dodawań/odejmowań – jeśli skorzystamy z faktu, że $\hat{x}^k = \hat{x}^{k-1} \hat{x}$. Jeśli natomiast użyjemy potęgowania (np. funkcji `pow()` w C lub zapisu typu `x^k` w Matlabie), to koszt będzie rzędu n^2 .

Zapisując wielomian f w nieco inny niż (2.1) sposób, można uzyskać algorytm o koszcie mniejszym niż (wymienione wyżej) $3n$ operacji arytmetycznych.

2.1 Schemat Hornera

Zapiszmy f jako

$$f(x) = a_0 + x(a_1 + x(\dots + x(a_{n-2} + x(a_{n-1} + xa_n)) \dots)). \quad (2.2)$$

Obliczenia będziemy wykonywać poczynawszy od wielomianu znajdującego się w najbardziej zagłębionym nawiasie.

Oznaczmy $w_n = a_n$, i obliczmy $w_{n-1} = a_{n-1} + \hat{x}w_n$. Następnie obliczymy $w_{n-2} = a_{n-2} + \hat{x}w_{n-1}$, itd. Ostatnią obliczoną wartością będzie $w_0 = f(\hat{x})$.

Algorytm 1 (Schemat Hornera)

```
w_n = a_n
for k = n - 1, n - 2, ..., 0
    w_k = a_k + \hat{x} w_{k+1}
end
f(\hat{x}) = w_0
```

Koszt tego algorytmu: n mnożeń i n dodawań (lub odejmowań).

Zauważmy jeszcze, że nie ma konieczności pamiętania wszystkich pośrednich wartości w_k , $k = n, \dots, 0$. W praktycznej implementacji wystarczy jedna zmienna (liczbowa). Algorytm 1a poniżej to zoptymalizowany w ten sposób algorytm Hornera.

Algorytm 1a (Schemat Hornera)

```
w = an
for k = n - 1, n - 2, ..., 0
    w = ak +  $\hat{x}$  w
end
f( $\hat{x}$ ) = w
```

2.2 Obliczanie wartości pochodnej wielomianu

Niech $f(x)$ oraz $\hat{x}$ będą zdefiniowane jak w poprzednim podrozdziale.

Zastanowimy się teraz, jak obliczyć wartość $f'(\hat{x})$.

Pierwsza możliwość, jaka się większości osób nasuwa, to zróżniczkować f , zapisany w postaci naturalnej, czyli wzorem (2.1) (otrzymamy wtedy f' w postaci naturalnej), a następnie zastosować schemat Hornera do f' . Jaki będzie koszt takiego algorytmu?

Innym podejściem (może nieco dziwnym na pierwszy rzut oka) będzie zróżniczkowanie wielomianu zapisanego w postaci (2.2). Niemniej zobaczymy, co z tego wyniknie. Korzystając z oznaczeń z poprzedniego podrozdziału, zapiszmy f jako

$$f(x) = a_0 + xw_1,$$

przy czym $w_1 = w_1(x)$, czyli w_1 jest funkcją zmiennej x .

Różniczkując f , korzystając przy tym z wzoru na pochodną iloczynu funkcji, otrzymujemy

$$f'(x) = w_1 + xw'_1.$$

Następnie obliczamy w'_1 i dostajemy

$$f'(x) = w_1 + xw'_1 = w_1 + x(w_2 + xw'_2).$$

Dalej obliczamy w'_2 , w'_3 , itd., aż dochodzimy do postaci:

$$f'(x) = w_1 + x(w_2 + x(\dots + x(w_{n-2} + x(w_{n-1} + xw_n)) \dots)). \quad (2.3)$$

Aby obliczyć $f'(\hat{x})$, postępujemy, jak poprzednio, rozpoczynając obliczenia od wyrażenia w najbardziej wewnętrznym nawiasie.

Algorytm 2 (Algorytm Hornera obliczania $f(\hat{x})$ i $f'(\hat{x})$)

```

 $w_n = a_n$ 
 $p_n = w_n$ 
for  $k = n - 1, n - 2, \dots, 1$ 
     $w_k = a_k + \hat{x} w_{k+1}$ 
     $p_k = w_k + \hat{x} p_{k+1}$ 
end
 $w_0 = a_0 + \hat{x} w_1$ 
 $f(\hat{x}) = w_0$ 
 $f'(\hat{x}) = p_1$ 

```

Koszt: $2n - 1$ mnożeń, $2n - 1$ dodawań (lub odejmowań).

Podobnie jak poprzednio (tj. w przypadku Algorytmu 1 i 1a), nie ma potrzeby pamiętania wszystkich pośrednich wartości w_k ($k = n, \dots, 0$) i p_k ($k = n, \dots, 1$).

Algorytm 2a poniżej to zoptymalizowany algorytm Hornera obliczania wartości wielomianu i jego pochodnej.

Algorytm 2a (Algorytm Hornera obliczania $f(\hat{x})$ i $f'(\hat{x})$)

```

 $w = a_n$ 
 $p = w$ 
for  $k = n - 1, n - 2, \dots, 1$ 
     $w = a_k + \hat{x} w$ 
     $p = w + \hat{x} p$ 
end
 $w = a_0 + \hat{x} w$ 
 $f(\hat{x}) = w$ 
 $f'(\hat{x}) = p$ 

```

2.3 Obliczanie wartości drugiej pochodnej wielomianu

Różniczkując f' zapisaną w postaci (2.3) otrzymamy algorytm obliczania wartości $f''(\hat{x})$, $f'(\hat{x})$ i $f(\hat{x})$.

Uwaga: należy pamiętać o tym, że $w_k = w_k(x)$, dla $k = 1, 2, \dots, n$, czyli są to funkcje x (przy różniczkowaniu zajdzie potrzeba skorzystania ze wzoru na pochodną funkcji złożonej).

Algorytm 3a (Algorytm Hornera obliczania $f(\hat{x})$, $f'(\hat{x})$ i $f''(\hat{x})$)

```
w = a_n
p = w
r = p
for k = n - 1, n - 2, ..., 2
    w := a_k + \hat{x} w
    p := w + \hat{x} p
    r := p + \hat{x} r
end
w := a_1 + \hat{x} w
p := w + \hat{x} p
w := a_0 + \hat{x} w
f(\hat{x}) := w
f'(\hat{x}) := p
f''(\hat{x}) := 2r
```

Jaki jest koszt tego algorytmu?

3 Interpolacja

Sformułowanie problemu:

Mając dane

- $x_i \in \mathbb{R}$, dla $i = 0, 1, \dots, n$ (węzły interpolacji)
- $f_i = f(x_i)$, gdzie f jest funkcją interpolowaną (nieznaną funkcją, której wartości są znane tylko w skończonej liczbie punktów)

znaleźć funkcję interpolującą p taką, że

$$p(x_i) = f(x_i), \quad \text{dla } i = 0, 1, \dots, n. \quad (3.1)$$

Funkcja p może mieć dowolną postać, w szczególności może być wielomianem lub przedziałami wielomianem.

W dalszej części zajmujemy się interpolacją wielomianową, czyli taką, gdzie funkcja p jest wielomianem.

3.1 Interpolacja wielomianowa

Zakładamy, że funkcja interpolująca p jest wielomianem.

Niech Π_n będzie przestrzenią wielomianów stopnia nie wyższego niż n , czyli wielomianów postaci $a_0 + a_1x + \dots + a_nx^n$, gdzie $a_i \in \mathbb{R}$ dla $i = 0, 1, \dots, n$.

Twierdzenie 3.1. *Jeśli węzły $x_0, x_1, \dots, x_n$ są parami różne ($x_i \neq x_j$ dla $i \neq j$, $i, j = 0, \dots, n$), to dla dowolnych wartości $f_i = f(x_i)$ istnieje dokładnie jeden wielomian $p_n \in \Pi_n$, taki, że*

$$p_n(x_i) = f(x_i), \quad \text{dla } i = 0, 1, \dots, n. \quad \square$$

3.2 Postać Lagrange’a wielomianu interpolacyjnego

Wielomian interpolacyjny jest wyznaczony jednoznacznie, ale można go przedstawić na różne sposoby (w różnych bazach) i wyznaczać różnymi algorytmami. Jednym z możliwych sposobów zapisania wielomianu interpolacyjnego jest postać Lagrange’a:

$$p_n(x) = \sum_{i=0}^n f_i l_i(x),$$

gdzie

$$l_i(x) = \prod_{\substack{j=0 \\ j \neq i}}^n \frac{x - x_j}{x_i - x_j}.$$

Wielomian interpolacyjny p_n przedstawiony jest w bazie wielomianów $l_0, l_1, \dots, l_n$. Nazywa się je wielomianami Lagrange'a. Każdy z tych wielomianów jest stopnia n .

Sprawdźmy, czy tak zdefiniowany wielomian p_n spełnia warunki interpolacji, czyli czy $p_n(x_k) = f(x_k)$ dla $k = 0, \dots, n$. Mamy

$$l_i(x_k) = \prod_{\substack{j=0 \\ j \neq i}}^n \frac{x_k - x_j}{x_i - x_j} = \begin{cases} 0 & \text{gdy } k \neq i, \\ 1 & \text{gdy } k = i, \end{cases}$$

a stąd

$$p_n(x_k) = \sum_{i=0}^n f_i l_i(x_k) = f_k,$$

czyli warunki interpolacji są spełnione.

Przykład 3.1. Niech będą dane węzły $x_i = i - 1$, $i = 0, 1, 2$, i wartości funkcji $f_0 = 1$, $f_1 = 0$, i $f_2 = 1$. Znaleźć wielomian interpolacyjny w postaci Lagrange'a dla funkcji f .

Rozwiązanie:

Węzłami są punkty $x_0 = -1$, $x_1 = 0$ i $x_2 = 1$.

Na trzech różnych punktach można skonstruować wielomian interpolacyjny drugiego stopnia. Jego postać Lagrange'a jest następująca:

$$p_2(x) = \sum_{i=0}^2 f_i l_i(x), \quad (3.2)$$

gdzie

$$l_i(x) = \prod_{\substack{j=0 \\ j \neq i}}^2 \frac{x - x_j}{x_i - x_j}, \quad i = 0, 1, 2.$$

Wyznamy wielomiany bazowe l_i . Dla $i = 0$ mamy

$$l_0(x) = \prod_{j=1}^2 \frac{x - x_j}{x_0 - x_j} = \frac{(x - x_1)(x - x_2)}{(x_0 - x_1)(x_0 - x_2)} = \frac{x(x - 1)}{-1 \cdot (-2)} = \frac{1}{2}x(x - 1).$$

Dla $i = 1$:

$$l_1(x) = \prod_{\substack{j=0 \\ j \neq 1}}^2 \frac{x - x_j}{x_1 - x_j} = \frac{(x - x_0)(x - x_2)}{(x_1 - x_0)(x_1 - x_2)} = \frac{(x + 1)(x - 1)}{-1} = -(x + 1)(x - 1),$$

i dla $i = 2$:

$$l_2(x) = \prod_{j=0}^1 \frac{x - x_j}{x_2 - x_j} = \frac{(x - x_0)(x - x_1)}{(x_2 - x_0)(x_2 - x_1)} = \frac{x(x + 1)}{2} = \frac{1}{2}x(x + 1).$$

Wstawiamy wyznaczone wielomiany bazowe l_i ($i = 0, 1, 2$) do wzoru (3.2) i otrzymujemy

$$p_2(x) = 1 \cdot \frac{1}{2}x(x - 1) + 1 \cdot \frac{1}{2}x(x + 1) = x^2.$$

Uwagi. Ponieważ $f_1 = 0$, nie było potrzeby wyznaczania l_1 . Nie ma także potrzeby sprowadzania wielomianu z postaci Lagrange’a do naturalnej – w przykładzie to zrobiono, aby lepiej było widać, jaką funkcję wyznaczyliśmy.

3.3 Postać Newtona wielomianu interpolacyjnego, schemat ilorazów różnicowych

Postać Newtona wielomianu interpolacyjnego:

$$p_n(x) = c_0 + c_1(x - x_0) + c_2(x - x_0)(x - x_1) + \dots + c_n(x - x_0)\dots(x - x_{n-1}). \quad (3.3)$$

Wielomian p_n jest przedstawiony w bazie $1, x - x_0, (x - x_0)(x - x_1), \dots, (x - x_0)\dots(x - x_{n-1})$. Zwróćmy uwagę, że w jego wzorze nie występuje w sposób widoczny węzeł x_n . Węzeł ten jest wykorzystywany przy wyznaczaniu współczynnika c_n .

Zauważmy, że $p_n(x_0) = c_0$. Z drugiej strony, z warunków interpolacji (3.1) mamy $p_n(x_0) = f(x_0)$. Zatem $c_0 = f(x_0)$.

Pozostałe współczynniki $c_1, \dots, c_n$ są równe

$$c_1 = f_{0,1},$$

$$c_2 = f_{0,1,2},$$

$\dots$,

$$c_n = f_{0,1,\dots,n},$$

gdzie $f_{0,1,\dots,k}$ dla $k = 1, \dots, n$ są *ilorazami różnicowymi*. Definiuje się je następująco.

Ilorazy różnicowe pierwszego rzędu konstruuje się w oparciu o dwa węzły, zgodnie ze wzorem:

$$f_{j,j+1} = \frac{f(x_{j+1}) - f(x_j)}{x_{j+1} - x_j} \quad \text{dla } j = 0, \dots, n - 1.$$

Ilorazy różnicowe drugiego rzędu definiuje się wykorzystując ilorazy pierwszego rzędu:

$$f_{j,j+1,j+2} = \frac{f_{j+1,j+2} - f_{j,j+1}}{x_{j+2} - x_j} \quad \text{dla } j = 0, \dots, n - 2.$$

Ogólnie, ilorazy różnicowe k -tego rzędu:

$$f_{j,j+1,\dots,j+k} = \frac{f_{j+1,\dots,j+k} - f_{j,\dots,j+k-1}}{x_{j+k} - x_j}$$

dla $j = 0, \dots, n - k$.

Uwaga 3.1. Ilorazy różnicowe można różnie oznaczać. Najczęściej stosuje się oznaczenia f_{0123} , $f_{0,1,2,3}$ lub $f[x_0, x_1, x_2, x_3]$. Zwykle będziemy używać pierwszego lub drugiego z nich (ponieważ są krótsze), ale czasem będziemy też korzystać z trzeciego, tam, gdzie będzie tego wymagała czytelność zapisu.

Najwygodniej jest obliczać ilorazy różnicowe wykorzystując schemat ilorazów różnicowych, wpisując kolejne obliczone ilorazy różnicowe do tabeli:

$$\begin{array}{ccccccc}
 x_0 & f_0 & & & & & \\
 x_1 & f_1 & \underline{f_{01}} = \frac{f_1 - f_0}{x_1 - x_0} & & & & \\
 x_2 & f_2 & \underline{f_{12}} = \frac{f_2 - f_1}{x_2 - x_1} & \underline{f_{012}} = \frac{f_{12} - f_{01}}{x_2 - x_0} & & & \\
 x_3 & f_3 & \underline{f_{23}} = \frac{f_3 - f_2}{x_3 - x_2} & \underline{f_{123}} = \frac{f_{23} - f_{12}}{x_3 - x_1} & \underline{f_{0123}} = \frac{f_{123} - f_{012}}{x_3 - x_0} & & \\
 \vdots & \vdots & \vdots & \vdots & \vdots & \ddots & \\
 x_n & f_n & \underline{f_{n-1,n}} = \frac{f_n - f_{n-1}}{x_n - x_{n-1}} & \underline{f_{n-2,n-1,n}} = \frac{f_{n-1,n} - f_{n-2,n-1}}{x_n - x_{n-2}} & \underline{f_{n-3,n-2,n-1,n}} & \cdots & \underline{f_{01\dots n}}
 \end{array}$$

Podkreślone elementy to współczynniki $c_0, \dots, c_n$ ($c_k = f_{0\dots k}$, $k = 0, 1, \dots, n$) wielomianu interpolacyjnego w postaci Newtona (3.3).

Przykład 3.2. Dla funkcji $f(x) = x^4$ znaleźć wielomian interpolacyjny $p_3(x)$ w postaci Newtona taki, że $p_3(-2) = f(-2)$, $p_3(-1) = f(-1)$, $p_3(0) = f(0)$ i $p_3(2) = f(2)$.

Rozwiązanie:

Węzłami interpolacji są punkty: $x_0 = -2$, $x_1 = -1$, $x_2 = 0$ i $x_3 = 2$.

Wielomian interpolacyjny w postaci Newtona skonstruowany na czterech węzłach jest stopnia co najwyżej 3 i jest następujący:

$$p_3(x) = c_0 + c_1(x - x_0) + c_2(x - x_0)(x - x_1) + c_3(x - x_0)(x - x_1)(x - x_2), \quad (3.4)$$

gdzie

$$c_0 = f(x_0),$$

$$c_1 = f_{01},$$

$$c_2 = f_{012},$$

$$c_3 = f_{0123}.$$

Dla czterech węzłów schemat ilorazów różnicowych ma następującą postać:

$$\begin{array}{ccccccc}
 x_0 & f_0 & & & & & \\
 x_1 & f_1 & \searrow & f_{01} & & & \\
 x_2 & f_2 & \searrow & f_{12} & \searrow & f_{012} & \\
 x_3 & f_3 & \searrow & f_{23} & \searrow & f_{123} & \searrow & f_{0123}
 \end{array}$$

Po podstawieniu wartości liczbowych dostajemy:

$$\begin{array}{rcl}
 -2 & 16 & \\
 -1 & 1 & \searrow \frac{1-16}{-1-(-2)} = -15 \\
 0 & 0 & \searrow \frac{0-1}{0-(-1)} = -1 \quad \searrow \frac{-1-(-15)}{0-(-2)} = 7 \\
 2 & 16 & \rightarrow \frac{16-0}{2-0} = 8 \quad \rightarrow \frac{8-(-1)}{2-(-1)} = 3 \quad \rightarrow \frac{3-7}{2-(-2)} = -1
 \end{array}$$

Współczynniki c_i ($i = 0, 1, 2, 3$) odczytujemy z tabeli: $c_0 = 16$, $c_1 = -15$, $c_2 = 7$, $c_3 = -1$.

Wielomian interpolacyjny w postaci Newtona jest zatem następujący:

$$p_3(x) = 16 - 15(x + 2) + 7(x + 2)(x + 1) - 1(x + 2)(x + 1)(x - 0).$$

Nie trzeba upraszczać tego wielomianu (tj. zmieniać bazy z $1, x - x_0, (x - x_0)(x - x_1), (x - x_0)(x - x_1)(x - x_2)$ na naturalną $1, x, x^2, x^3$).

Uwaga 3.2. W praktyce nie zaleca się zmiany bazy Newtona na naturalną. Baza Newtona ma lepsze własności numeryczne, a ponadto łatwo jest zmodyfikować algorytm Hornera tak, aby można nim było obliczać wartości wielomianu interpolacyjnego w postaci Newtona.

3.4 Uogólniony schemat Hornera

Schemat Hornera obliczania wartości wielomianu w postaci Newtona w punkcie $\hat{x} \in \mathbb{R}$. Zapiszmy $p_n(x)$ jako

$$\begin{aligned}
 p_n(x) = & \\
 c_0 + (x - x_0) & (c_1 + (x - x_1) (\dots + (x - x_{n-3}) (c_{n-2} + (x - x_{n-2}) (c_{n-1} + (x - x_{n-1}) c_n) \dots)).
 \end{aligned}$$

Algorytm (uogólniony schemat Hornera)

```

w = c_n
for k = n - 1, n - 2, ..., 0
    w = c_k + (x̂ - x_k) w
end
p_n(x̂) = w

```

Koszt: n mnożeń, $2n$ dodawań/odejmowań.

3.5 Błąd interpolacji, zbieżność procesów interpolacyjnych, dobór węzłów

Dokonując interpolacji, czyli przybliżając pewną (najczęściej nieznaną) funkcję, inną funkcją, warto zastanowić się, jaki jest błąd tego przybliżenia.

Podamy teraz podstawowe twierdzenie dotyczące błędu interpolacji wielomianowej.

Twierdzenie 3.2. *Jeśli $f \in C^{n+1}([a, b])$, a wielomian $p_n \in \Pi_n$ jest wielomianem interpolacyjnym dla f opartym na parami różnych węzłach $x_0, \dots, x_n \in [a, b]$, to dla każdego $x \in [a, b]$ istnieje takie $\xi \in (a, b)$, że*

$$f(x) - p_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} (x - x_0)(x - x_1) \dots (x - x_n). \quad \square$$

Najczęściej dokładna wartość ξ nie jest znana. Wiemy tylko tyle, że $\xi \in (a, b)$. Dlatego w praktyce korzysta się z oszacowania błędu.

Wniosek 3.1. *(z Twierdzenia 3.2) Jeśli $f \in C^{n+1}([a, b])$ oraz $p_n \in \Pi_n$ jest wielomianem interpolacyjnym dla f opartym na parami różnych węzłach $x_0, \dots, x_n \in [a, b]$, to dla każdego $x \in [a, b]$ zachodzi oszacowanie*

$$|f(x) - p_n(x)| \leq \frac{M_{n+1}}{(n+1)!} |(x - x_0)(x - x_1) \dots (x - x_n)|,$$

gdzie

$$M_{n+1} = \max_{x \in [a, b]} |f^{(n+1)}(x)|. \quad \square$$

Patrząc na powyższe twierdzenie (oraz wniosek) widzimy, że (przy ustalonym n) błąd interpolacji zależy od funkcji, którą interpolujemy (a konkretniej, od jej $n+1$ -ej pochodnej) oraz od węzłów. To raczej nie są bardzo zaskakujące obserwacje, niemniej możemy zadać sobie pytanie: co zrobić (jak dobrać parametry problemu), aby błąd był jak najmniejszy. W przypadku, gdy funkcja f jest nieznaną (np. gdy dokonujemy interpolacji na danych z pomiaru, sporządzonego w skończonej liczbie punktów), nie znamy ani $f^{(n+1)}$, ani może się nie dać dobrze oszacować M_{n+1} . Poza tym, nawet, jeśli znamy $f^{(n+1)}$, to nie mamy na nią wpływu. Możemy mieć natomiast wpływ na dobór węzłów. Można się starać tak dobrać węzły $x_0, \dots, x_n$, aby zminimalizować wielkość

$$r_n = \max_{x \in [a, b]} |(x - x_0)(x - x_1) \dots (x - x_n)|. \quad (3.5)$$

Węzły równoodległe (tj. $x_k = a + kh$, gdzie $h = \frac{b-a}{n}$, $k = 0, 1, \dots, n$) nie są dobrym wyborem. Zauważmy, że wielomian $(x - x_0)(x - x_1) \dots (x - x_n)$ (zbudowany na węzłach

równoodległych) ma największe wartości blisko brzegów przedziału $[a, b]$, a mniejsze bliżej jego środka (warto zrobić wykres tego wielomianu – w Matlabie lub innym programie – np. dla $[a, b] = [-1, 1]$, $n = 20$). Najlepsze byłyby takie węzły, przy których wartości analogicznego wielomianu są zbliżone w całym przedziale $[a, b]$. Dzieje się tak, gdy węzłami są pierwiastki wielomianów Czebyszewa. Wielomian Czebyszewa n -tego stopnia (dla $[a, b] = [-1, 1]$) zdefiniowany jest wzorem:

$$T_n(x) = \cos(n \arccos x), \quad \text{dla } x \in [-1, 1], \quad n = 0, 1, \dots \quad (3.6)$$

Wielomiany Czebyszewa spełniają związek rekurencyjny

$$T_0(x) = 1, \quad T_1(x) = x, \quad T_k(x) = 2xT_{k-1}(x) - T_{k-2}(x), \quad k = 2, 3, \dots$$

Wielomian Czebyszewa stopnia $n + 1$ (dla $[a, b] = [-1, 1]$) ma następujące pierwiastki

$$x_i = \cos\left(\frac{2i+1}{2n+2}\pi\right) \quad i = 0, 1, \dots, n. \quad (3.7)$$

Ze wzoru trygonometrycznego (3.6) wynika, że $\max_{x \in [-1, 1]} |T_n(x)| = 1$, dla każdego $n = 1, 2, \dots$. Ponadto, prawdziwa jest równość

$$(x - x_0)(x - x_1) \dots (x - x_n) = 2^{-n} T_{n+1}.$$

Zatem dla węzłów Czebyszewa otrzymujemy następujące oszacowanie błędu interpolacji

$$|f(x) - p_n(x)| \leq \frac{M_{n+1}}{2^n(n+1)!}.$$

Co więcej, jeśli chodzi o dobór węzłów, jest to najlepsze oszacowanie. W 1857r. P. Czebyszew udowodnił, że dla $[a, b] = [-1, 1]$ wartość r_n (określona wzorem (3.5)) osiąga minimum, gdy węzłami są punkty (3.7). Dlatego teraz te punkty nazywane są węzłami Czebyszewa. Wynik uzyskany przez Czebyszewa można sformułować w następujący sposób.

Twierdzenie 3.3. *Spośród wszystkich wielomianów postaci $p(x) = x^{n+1} + w(x)$, gdzie $w \in \Pi_n$, najmniejszą wartość $\max_{x \in [-1, 1]} |p(x)|$ ma wielomian $2^{-n} T_{n+1}$.* $\square$

Uwaga 3.3. *Gdy chcemy użyć węzłów Czebyszewa na dowolnym przedziale $[a, b]$, możemy je liniowo przeskalować. Otrzymujemy:*

$$x_i = \frac{a+b}{2} - \frac{b-a}{2} \cos\left(\frac{2i+1}{2n+2}\pi\right) \quad i = 0, 1, \dots, n.$$

3.5.1 Zbieżność procesów interpolacyjnych. Zjawisko Rungego

Rozwiązując zadania interpolacyjne można się zastanawiać, czy dla każdego zadania da się tak dobrać liczbę węzłów oraz rodzaj (równoodległe, Czebyszewa, itp.), aby błąd interpolacji był dowolnie mały. W pewnym stopniu odpowiadają na to następujące trzy twierdzenia.

Twierdzenie 3.4. (Weierstrassa) *Jeśli funkcja f jest ciągła w przedziale $[a, b]$, to dla każdego $\varepsilon > 0$ istnieje taki wielomian p , że $\max_{x \in [a, b]} |f(x) - p(x)| \leq \varepsilon$.*

Można powiedzieć, że twierdzenie to jest optymistyczne. Dzięki niemu wiemy, że dowolną funkcję ciągłą można dowolnie blisko przybliżyć wielomianem. Ciągłość nie musi być ograniczeniem. Większość zjawisk w przyrodzie ma charakter ciągły. Na przykład, temperatura, wilgotność, itp. zmieniają się w sposób ciągły. Jeśli chcemy stworzyć model ruchu jakiegoś obiektu w czasie (np. jadącego samochodu czy rzuconej piłki), to ruch ten odbywa się po krzywej ciągłej.

Z twierdzeniem Weierstrassa jest jednak taki problem, że jest ono egzystencjalne. Mówi nam, że odpowiedni wielomian istnieje, ale nie mówi, jak go określić.

Można tworzyć różne układy węzłów (np. Czebyszewa, równoodległe, jeszcze inne), ale nie ma uniwersalnego układu węzłów, który gwarantowałby zbieżność ciągu wielomianów interpolacyjnych na nich skonstruowanych do każdej funkcji. Mówi o tym następujące twierdzenie.

Twierdzenie 3.5. (Fabera) *Dla dowolnego ciągu układów węzłów $a \leq x_0^{(n)} < x_1^{(n)} < \dots < x_n^{(n)} \leq b$, gdzie $n \geq 0$, istnieje taka funkcja ciągła w $[a, b]$, że ciąg wielomianów interpolacyjnych zbudowanych na tych węzłach nie jest do niej zbieżny.*

Zakończymy ten wątek trzecim twierdzeniem, znów optymistycznym.

Twierdzenie 3.6. *Jeśli f jest funkcją ciągłą w $[a, b]$, to istnieje taki ciąg układów węzłów $a \leq x_0^{(n)} < x_1^{(n)} < \dots < x_n^{(n)} \leq b$, gdzie $n \geq 0$, że zbudowane na nich wielomiany interpolacyjne tworzą ciąg zbieżny do f .*

Problem znalezienia takiego ciągu pozostaje jednak nierozwiązany.


Zastanówmy się teraz, jak liczba oraz rozkład węzłów może wpływać na błąd interpolacji. Większa liczba węzłów oznacza, że mamy więcej informacji o funkcji interpolowanej. Poza tym, we wzorze określającym błąd interpolacji (Twierdzenie 3.2) czy oszacowaniu błędu (Wniosek 3.1) w mianowniku mamy $(n+1)!$, a więc wartość szybko rosnącą wraz z liczbą węzłów. To może sugerować, że zwiększając liczbę węzłów dostajemy coraz lepsze przybliżenie funkcji f . Nie zawsze jednak tak się dzieje. Nie zapominajmy, że błąd interpolacji zależy też od wartości wyrażenia $(x - x_0)(x - x_1) \dots (x - x_n)$ oraz od wartości $f^{(n+1)}$, a te mogą być bardzo duże.

Poza tym, co z funkcjami, które nie są różniczkowalne? O nich Twierdzenie 3.2 nic nie mówi.

Przykład 3.3.

Zobaczmy, jak w praktyce może zachowywać się błąd interpolacji gdy zwiększamy liczbę węzłów.

Niech $f_1(x) = |x|$. Rysunek 1 przedstawia wykresy funkcji f_1 i jej wielomianów interpolacyjnych skonstruowanych na dla 7, 11 i 15 równoodległych węzłów z przedziału $[-1, 1]$.



Rysunek 1: Wykresy wielomianów interpolacyjnych dla funkcji $f_1(x) = |x|$, skonstruowanych na węzłach równoodległych z przedziału $[-1, 1]$. Liczba węzłów: 7 (lewy wykres), 11 (środkowy wykres) i 15 (prawy wykres).

Widać, że w tym przypadku ciąg wielomianów interpolacyjnych rosnących stopni nie jest zbieżny do funkcji interpolowanej. Największe wartości błędów są dla argumentów leżących blisko krańców przedziału interpolacji (porównaj wyjaśnienia znajdujące się bezpośrednio po wzorze (3.5)).

Wykonajmy teraz analogiczny test dla funkcji $f_2(x) = \frac{1}{1 + 15x^2}$. Rysunek 2 przedstawia wykresy funkcji f_2 oraz jej wielomianów interpolacyjnych zbudowanych na 6, 12, 16 i 20 węzłach równoodległych z przedziału $[-1, 1]$.

Zjawisko, które tu obserwujemy jest dość częste przy interpolacji wielomianami wysokich stopni opartymi na węzłach równoodległych. Nosi ono nazwę *zjawiska Rungego*, a funkcja postaci $f(x) = \frac{1}{1 + ax^2}$, gdzie $a \geq 1$, nazywana jest funkcją Rungego.


Sprawdźmy teraz, jakie wyniki uzyskamy, gdy zastosujemy węzły Czebyszewa.

Rysunki przedstawiają wykresy funkcji f_1 i f_2 oraz ich wielomianów interpolacyjnych skonstruowanych na węzłach Czebyszewa. Liczba węzłów jest taka sama jak w teście dla węzłów równoodległych.


3.6 Interpolacja Hermite'a

Interpolacja Hermite'a to interpolacja z węzłami wielokrotnymi (w węzłach mamy dane nie tylko wartości funkcji interpolowanej, ale też jej pochodnych).

Niech $x_i \in \mathbb{R}$, dla $i = 0, 1, \dots, m$, takie, że $x_i \neq x_j$ dla $i \neq j$, $i, j = 0, 1, \dots, m$ będą węzłami interpolacji, a f niech będzie funkcją interpolowaną, dostatecznie wiele razy



Rysunek 2: Wykresy wielomianów interpolacyjnych dla funkcji $f_2(x) = \frac{1}{1+15x^2}$, skonstruowanych na węzłach równoodległych z przedziału $[-1, 1]$. Liczba węzłów: 6, 12 i 16 (wykresy górne) oraz 20 (wykres dolny).



Rysunek 3: Wykresy wielomianów interpolacyjnych dla funkcji $f_1(x) = |x|$, skonstruowanych na węzłach Czebyszewa z przedziału $[-1, 1]$. Liczba węzłów: 7 (lewy wykres), 11 (środkowy wykres) i 15 (prawy wykres).


różniczkowalną (zakładamy, że istnieją wartości pochodnych f , które wykorzystujemy w interpolacji).

Zadanie interpolacji Hermite'a polega na poszukiwaniu wielomianu (interpolacyjnego) p takiego, że

$$p^{(j)}(x_i) = f^{(j)}(x_i), \quad \text{dla } j = 0, 1, \dots, k_i - 1, \quad i = 0, 1, \dots, m, \quad (3.8)$$

gdzie wszystkie wartości $f^{(j)}(x_i)$ są dane. Stałe k_i są dane, definiują krotność węzłów. Często spotykanym przypadkiem interpolacji Hermite'a jest, gdy $k_i = 2$, dla $i = 0, 1, \dots, m$, czyli wszystkie węzły są dwukrotne (w każdym jest zadana wartość funkcji f i jej pierwszej pochodnej).

Oznaczmy łączną liczbę warunków przez $n + 1$. Zatem $n + 1 = k_0 + k_1 + \dots + k_m$.



Rysunek 4: Wykresy wielomianów interpolacyjnych dla funkcji $f_2(x) = \frac{1}{1+15x^2}$, skonstruowanych na węzłach Czebyszewa z przedziału $[-1, 1]$. Liczba węzłów: 6, 12 i 16 (wykresy górne) oraz 20 (wykres dolny).

Twierdzenie 3.7. *W klasie Π_n istnieje dokładnie jeden wielomian p spełniający warunki (3.8).*

Wielomian interpolacyjny Hermite’a jest zatem określony jednoznacznie. Dzięki następnemu twierdzeniu oraz uwadze będziemy mogli go łatwo wyznaczyć.

Twierdzenie 3.8. *Jeśli $f \in C([a, b])$ oraz $x_i \in [a, b]$, $i = 0, 1, \dots, m$, przy czym $x_i \neq x_j$ dla $i \neq j$, $i, j = 0, 1, \dots, m$, to istnieje takie $\xi \in (a, b)$, że*

$$f[x_0, x_1, \dots, x_m] = \frac{1}{m!} f^{(m)}(\xi).$$

Uwaga 3.4. *Gdy długość przedziału $[a, b]$ w Twierdzeniu 3.8 dąży do zera, otrzymujemy w granicy równość*

$$f[x_0, x_0, \dots, x_0] = \frac{1}{m!} f^{(m)}(x_0).$$

W przypadku interpolacji Hermite’a wielomian interpolacyjny (w postaci Newtona) można budować korzystając ze schematu ilorazów różnicowych, przyjmując

$$f_{ii\dots i} = f[x_i, x_i, \dots, x_i] = \frac{1}{k!} f^{(k)}(x_i). \quad (3.9)$$

W powyższym wzorze, w każdym z oznaczeń $f_{ii\dots i}$ i $f[x_i, x_i, \dots, x_i]$ znak i pojawia się $k + 1$ razy.

Przykład 3.4. Dla funkcji $f(x) = -x^4$ znaleźć wielomian interpolacyjny Hermite'a $p_3(x)$ w postaci Newtona taki, że $p_3(-1) = f(-1)$, $p_3(1) = f(1)$, $p'_3(1) = f'(1)$ i $p''_3(1) = f''(1)$.

Rozwiązanie:

Węzłami interpolacji są punkty: $x_0 = -1$ (węzeł jednokrotny) i $x_1 = 1$ (węzeł trzykrotny). Wielomian interpolacyjny w postaci Newtona konstruowany na tych węzłach jest następujący:

$$p_3(x) = c_0 + c_1(x - x_0) + c_2(x - x_0)(x - x_1) + c_3(x - x_0)(x - x_1)^2. \quad (3.10)$$

Współczynniki tego wielomianu odczytamy z tablicy ilorazów różnicowych.

W przypadku interpolacji Hermite'a tabelę ilorazów różnicowych konstruujemy podobnie jak przy interpolacji z węzłami jednokrotnymi, przy czym w pierwszej kolumnie umieszczamy każdy węzeł tyle razy, ile mamy z nim związanych warunków, przez co liczba elementów w każdej z dwóch pierwszych kolumn będzie równa łącznej liczbie warunków. W drugiej kolumnie umieszczamy wartości funkcji interpolowanej, a w kolejnych kolumnach ilorazy różnicowe (tam, gdzie jest to możliwe, tj. tam, gdzie próba policzenia ilorazu różnicowego nie prowadzi do dzielenia 0 przez 0) lub wartości wynikające ze wzoru (3.9). W tym przykładzie schemat ten będzie wyglądał następująco:

$$\begin{array}{ccccccc} x_0 & f_0 & & & & & \\ x_1 & f_1 & \nearrow & f_{01} & & & \\ x_1 & f_1 & \nearrow & \mathbf{f}_{11} & \nearrow & f_{011} & \\ x_1 & f_1 & \nearrow & \mathbf{f}_{11} & \nearrow & \mathbf{f}_{111} & \nearrow f_{0111} \end{array}$$

Wartości pogrubionych elementów obliczymy korzystając ze wzoru (3.9).

Po podstawieniu wartości liczbowych dostajemy:

$$\begin{array}{ccccccc} -1 & -1 & & & & & \\ 1 & -1 & \nearrow & \frac{-1-(-1)}{1-(-1)} = 0 & & & \\ 1 & -1 & \nearrow & f_{11} = f'(x_1) = -4 & \nearrow & \frac{-4-0}{1-(-1)} = -2 & \\ 1 & -1 & \nearrow & f_{11} = f'(x_1) = -4 & \nearrow & f_{111} = \frac{1}{2}f''(x_1) = -6 & \nearrow \frac{-6-(-2)}{1-(-1)} = -2 \end{array}$$

Współczynniki c_i ($i = 0, 1, 2, 3$) odczytujemy z tabeli: $c_0 = -1$, $c_1 = 0$, $c_2 = -2$, $c_3 = -2$.

Wielomian interpolacyjny Hermite'a (w postaci Newtona) jest zatem następujący:

$$p_3(x) = -1 - 2(x + 1)(x - 1) - 2(x + 1)(x - 1)^2.$$

Można go także zapisać przyjmując odwrotną kolejność węzłów:

$$p_3(x) = -1 - 4(x - 1) - 6(x - 1)^2 - 2(x - 1)^3.$$

Dzięki Twierdzeniu 3.7 wiemy, że jest to ten sam wielomian, ale jeśli ktoś ma ochotę, to zawsze można to sprawdzić (sprowadzając do tej samej bazy).

Dodatkowa lektura: podrozdział 6.0, 6.1, 6.2 i 6.3 z pozycji [1].

4 Całkowanie numeryczne

Problemem, którym się teraz zajmiemy, będzie obliczanie (najczęściej w sposób przybliżony) wartości całki oznaczonej

$$I(f) = \int_a^b f(x)dx, \quad (4.1)$$

gdzie $f : [a, b] \rightarrow \mathbb{R}$ jest funkcją całkowalną.

Dlaczego potrzebne są metody numerycznego całkowania?

- Funkcja pierwotna nie zawsze istnieje, zatem nie zawsze jesteśmy w stanie obliczyć całkę analitycznie. Z drugiej strony, całki, które pojawiają się w praktycznych zastosowaniach, często wyrażają jakąś wielkość fizyczną (np. masa, rozkład ładunku elektrycznego) albo wynikają z równań różniczkowych które modelują jakieś zjawiska fizyczne. Zatem, nawet jeśli funkcja pierwotna nie istnieje, wielkość, którą całka opisuje, jak najbardziej może istnieć i możemy próbować ją obliczyć w sposób przybliżony.
- Funkcja f może być dana w postaci dyskretnej, jako zbiór punktów i wartości w tych punktach (przykładem takiej funkcji są dane pomiarowe) zatem nie da się jej scałkować analitycznie.
- Są także takie przypadki, gdzie funkcja pierwotna istnieje, ale ma taką postać, że numeryczne obliczenie całki $I(f)$ jest szybsze i dokładniejsze niż analityczne.

Z zagadnieniem przybliżonego obliczania całek wiąże się pojęcie kwadratury.

4.1 Kwadratury

Kwadratury (czyli wzory przybliżonego całkowania) pozwalają obliczyć przybliżoną wartość całki $I(f)$. Będziemy rozważać kwadratury postaci

$$S(f) = \sum_{k=0}^n A_k f(x_k), \quad (4.2)$$

gdzie

- punkty $x_k \in [a, b]$, dla $k = 0, \dots, n$, oraz $x_k \neq x_j$ dla $k \neq j$ ($k, j = 0, \dots, n$) nazywane są węzłami kwadratury,
- A_k , dla $k = 0, \dots, n$, są współczynnikami kwadratury; są to stałe niezależne od f .

Zauważmy, że aby obliczyć przybliżoną wartość całki za pomocą wzoru (4.2), musimy znać wartości funkcji f *tylko w węzłach* tej kwadratury.

Wzór (4.2) to ogólna postać kwadratury. Aby uzyskać konkretną metodę (kwadraturę), trzeba określić liczbę węzłów (czyli związana z nią wartość n) oraz wartości węzłów i współczynników.

Powstaje pytanie: jak (przy ustalonym n) dobrać współczynniki A_k oraz węzły x_k , dla $k = 0, \dots, n$, aby wzór (4.2) jak najlepiej przybliżał wartość całki (4.1)? Innymi słowy, jak dobrać parametry kwadratury, aby jej błąd, czyli

$$E(f) = I(f) - S(f),$$

był mały (tj. jak najbliższy zeru)?

Kwadratura $S(f)$ przy ustalonym n ma $2n + 2$ parametry, tj. $n + 1$ węzłów i $n + 1$ współczynników. Często wyznacza się je zakładając, że $I(f) = S(f)$ dla wielomianów określonego stopnia.

Z tym wiąże się też pojęcie rzędu kwadratury.

Definicja 4.1. Kwadratura $S(f)$ jest rzędu r , jeśli

- 1) jest dokładna (czyli $E(f) = 0$) dla wszystkich wielomianów stopnia mniejszego niż r , oraz
- 2) istnieje wielomian stopnia r , dla którego $S(f)$ nie jest dokładna.

4.2 Kwadratury interpolacyjne

Bardzo ważną grupę kwadratur (i jedyną omawianą na tym wykładzie) stanowią kwadratury interpolacyjne.

Idea ich konstrukcji jest taka: funkcję podcałkową f zastępujemy funkcją p , która jest funkcją interpolującą dla f i jednocześnie jest łatwa do całkowania; następnie przyjmujemy, że $S(f) = I(p)$, czyli przybliżeniem całki $I(f)$ jest całka z funkcji interpolującej. Najczęściej funkcją interpolującą jest po prostu wielomian interpolacyjny Lagrange’a (czyli oparty na węzłach jednokrotnych). Węzłami kwadratury są węzły interpolacji.

Skonstruujemy teraz pewne kwadratury interpolacyjne. Zastosujemy wielomian interpolacyjny Lagrange’a, zapisany w postaci Lagrange’a, czyli:

$$p_n(x) = \sum_{k=0}^n f(x_k) l_k(x), \quad \text{gdzie} \quad l_k(x) = \prod_{j=0, j \neq k}^n \frac{x - x_j}{x_k - x_j}.$$

Po zastąpieniu f wielomianem p_n w całce (4.1) otrzymujemy:

$$\begin{aligned} I(f) &= \int_a^b f(x)dx \approx \int_a^b p_n(x)dx \\ &= \int_a^b \sum_{k=0}^n f(x_k)l_k(x)dx = \sum_{k=0}^n f(x_k) \int_a^b l_k(x)dx. \end{aligned}$$

Skorzystaliśmy z faktu, że całka sumy funkcji jest równa sumie całek oraz z tego, że $f(x_k) \in \mathbb{R}$, zatem można tę wartość wyłączyć przed całkę.

Porównując teraz ostatnie wyrażenie w powyższym wzorze z ogólnym wzorem kwadratury (4.2), widzimy, że jeśli przyjmiemy

$$A_k = \int_a^b l_k(x)dx \quad \text{dla } k = 0, \dots, n, \quad (4.3)$$

to otrzymaliśmy kwadraturę. Węzłami x_k są węzły interpolacji, a współczynniki A_k możemy obliczyć z powyższego wzoru, całkując wielomiany l_k .

Pojawia się teraz jeszcze pytanie: jak wybrać węzły? Można to zrobić w dowolny sposób, pamiętając tylko o tym, że węzły mają być (parami) różne oraz, że mają należeć do przedziału $[a, b]$.

W praktyce, jeśli z góry narzuca się wartości węzłów, to są to najczęściej węzły równoodległe (oparte na nich kwadratury noszą nazwę kwadratur Newtona-Cotesa). Można też nie narzucać konkretnych wartości, tylko starać się je tak dobrać (obliczyć), aby zmaksymalizować rząd kwadratury (co podniesie jej dokładność). Takie kwadratury to kwadratury Gaussa.

4.3 Kwadratury Newtona-Cotesa (proste)

W przypadku, gdy węzły są równoodległe oraz $x_0 = a$ i $x_n = b$ (czyli $x_k = a + hk$, gdzie $h = (b - a)/n$), wzór

$$S(f) = \sum_{k=0}^n f(x_k)A_k$$

przy A_k zdefiniowanych wzorem (4.3), nosi nazwę kwadratury Newtona-Cotesa.

Rozpatrzmy teraz kilka przypadków szczególnych kwadratur tego typu. Będą to kwadratury *proste*, nazywane tak w przeciwieństwie do kwadratur złożonych, które będą opisane w podrozdziale 4.4.

4.3.1 Kwadratura (wzór) trapezów (prosta)

Dla $n = 1$ otrzymujemy kwadraturę dwupunktową (czyli opartą na dwóch węzłach), której węzłami są końce przedziału całkowania: a i b . Nosi ona nazwę kwadratury (wzoru) trapezów i ma postać:

$$S(f) = \frac{b-a}{2}(f(a) + f(b)).$$

Funkcja f jest przybliżana wielomianem stopnia 1. Jeśli $f(a) > 0$ oraz $f(b) > 0$, to $S(f)$ jest polem trapezu, utworzonego przez odcinek $[a, b]$, wykres wielomianu interpolacyjnego przybliżającego f na odcinku $[a, b]$ oraz odcinków łączących punkty $(a, 0)$ i $(a, f(a))$ oraz $(b, 0)$ i $(b, f(b))$.



Rysunek 5: Graficzna interpretacja metody trapezów: niebieska linia to wykres funkcji podcałkowej, czerwona linia to wykres przybliżającego ją wielomianu interpolacyjnego opartego na węzłach a i b .

Uwaga 4.1. Jeśli funkcja podcałkowa nie ma dodatnich wartości w punktach a lub b , wartość kwadratury nie może być interpretowana jako pole trapezu (wartość kwadratury nie musi być dodatnia, a odpowiednia figura nie musi być trapezem).

Błąd prostej kwadratury trapezów wynosi:

$$E(f) = -h^3 \frac{1}{12} f''(\xi_1),$$

gdzie $h = b - a$, a ξ_1 jest pewnym punktem leżącym w przedziale (a, b) .

Zauważmy, że błąd $E(f)$ jest zerowy, gdy $f''(x) = 0$ dla wszystkich $x \in (a, b)$, co ma miejsce w przypadku wielomianów stopnia 1 lub 0. Natomiast, gdy f jest wielomianem stopnia 2, to $f''(x) \neq 0$.

Dlatego rząd kwadratury trapezów jest równy 2.

Dokładna wartość błędu może być trudna do określenia, ponieważ nie znamy wartości ξ_1 . Szacując f'' z góry i z dołu można otrzymać oszacowania błędu.

4.3.2 Kwadratura (wzór) Simpsona (prosta)

Gdy $n = 2$, mamy 3 węzły: a , b i $\frac{a+b}{2}$. Kwadratura na nich skonstruowana to kwadratura (wzór) Simpsona, zwana również wzorem parabol.

Funkcja f jest przybliżana wielomianem stopnia 2. W tym przypadku kwadratura ma postać

$$S(f) = \frac{b-a}{6} \left(f(a) + 4f\left(\frac{a+b}{2}\right) + f(b) \right).$$

Błąd prostej kwadratury Simpsona wynosi:

$$E(f) = -h^5 \frac{1}{90} f^{(4)}(\xi_2),$$

gdzie $h = \frac{b-a}{2}$, a ξ_2 jest pewnym punktem leżącym w przedziale (a, b) .

W tym przypadku błąd $E(f)$ jest równy zero, gdy $f^{(4)}(x) = 0$, dla wszystkich $x \in (a, b)$, co ma miejsce w przypadku wielomianów stopnia nie przekraczającego 3. Dlatego rząd kwadratury Simpsona wynosi 4.

Zauważmy, że wielomian interpolacyjny skonstruowany na trzech węzłach jest stopnia co najwyżej 2, zatem błąd interpolacji dla wielomianu stopnia 3 jest niezerowy. Kwadratura Simpsona, natomiast, jest dokładna dla wszystkich wielomianów stopnia 3 (por. Twierdzenie 4.1 oraz Uwaga 4.3).

4.3.3 Kwadratura (wzór) Newtona 3/8 (prosta)

Dla $n = 3$ kwadratura jest oparta na 4 węzłach: a , b , $\frac{2a+b}{3}$ i $\frac{a+2b}{3}$.

Funkcja f jest przybliżana wielomianem stopnia 3. Kwadratura Newtona „ $\frac{3}{8}$ ” („trzech ósmych”) ma postać:

$$S(f) = \frac{b-a}{8} \left(f(a) + 3f\left(\frac{2a+b}{3}\right) + 3f\left(\frac{a+2b}{3}\right) + f(b) \right),$$

gdzie $h = \frac{b-a}{3}$.

Błąd tej kwadratury wynosi

$$E(f) = -h^5 \frac{3}{80} f^{(4)}(\xi_3),$$

dla pewnego $\xi_3 \in (a, b)$.

Rząd kwadratury Newtona $\frac{3}{8}$ wynosi 4 (jest TAKI SAM jak kwadratury Simpsona) – porównaj Twierdzenie 4.1 oraz Uwaga 4.3.

4.3.4 Kwadratura prostokątów (prosta)

Dla $n = 0$ warunek $x_0 = a$, $x_n = b$ nie może być spełniony, zatem kwadratura jednopunktowa (czyli oparta na jednym węźle) często (tj. w wielu źródłach) nie jest zaliczana do kwadratur Newtona-Cotesa.

Kwadratura oparta na jednym węźle $x_0 \in [a, b]$ nosi nazwę kwadratury (wzoru) prostokątów. Jest następująca:

$$S(f) = (b-a)f(x_0).$$

Funkcja podcałkowa f jest w tym przypadku przybliżana wielomianem stopnia 0 opartym na węźle x_0 .

Węzłem x_0 może być dowolny punkt należący do przedziału $[a, b]$, ale najczęściej stosuje się $x_0 = \frac{a+b}{2}$, czyli środek przedziału. Można udowodnić, że w tym przypadku błąd kwadratury prostokątów wyraża się wzorem

$$E(f) = h^3 \frac{1}{24} f''(\xi_4),$$

gdzie $h = b - a$, a ξ_4 jest pewnym punktem leżącym w przedziale (a, b) .

Rząd kwadratury prostokątów (z węzłem środkowym) wynosi więc 2 (*jest taki sam, jak w przypadku kwadratury trapezów*).

Uwaga 4.2. *Jeśli węzłem nie jest środek przedziału, to rząd kwadratury prostokątów jest równy 1.*

Ogólnie, błąd kwadratur Newtona-Cotesa określony jest przez następujące twierdzenie.

Twierdzenie 4.1. *Błąd kwadratury Newtona-Cotesa wyraża się wzorem*

$$\begin{aligned} E(f) &= I(f) - S(f) = \int_a^b (f(x) - p_n(x)) dx = \\ &= \begin{cases} h^{n+3} \kappa_n f^{(n+2)}(\xi), & \text{dla parzystych } n, \\ h^{n+2} \hat{\kappa}_n f^{(n+1)}(\xi), & \text{dla nieparzystych } n, \end{cases} \end{aligned}$$

dla pewnego $\xi \in (a, b)$, gdzie

$$\begin{aligned} \kappa_n &= \frac{1}{(n+2)!} \int_0^n t^2(t-1) \dots (t-n) dt, \\ \hat{\kappa}_n &= \kappa_{n-1} + \frac{1}{(n+1)!} \int_{n-1}^n t(t-1) \dots (t-n) dt. \end{aligned}$$

Uwaga 4.3. *Będzie na wykładzie.*

4.4 Kwadratury złożone


Uwaga 4.4. *Gdy $n \geq 7$ (z wyjątkiem 9) niektóre współczynniki kwadratur Newtona-Cotesa są ujemne, co może prowadzić do zwiększenia wpływu błędów zaokrągleń na wynik.*

Z tego względu w celu zwiększenia dokładności nie stosuje się kwadratur opartych na interpolacji wielomianem wysokiego stopnia, tylko kwadratury złożone.

Idea kwadratur złożonych: Przedział $[a, b]$ dzielimy na N podprzedziałów równej długości, na każdym stosujemy kwadraturę prostą i sumujemy uzyskane wartości.

4.4.1 Złożona kwadratura trapezów

Przedział $[a, b]$ dzielimy na podprzedziały $[x_{k-1}, x_k]$ ($k = 1, \dots, N$), o długości $H = \frac{b-a}{N}$, przy czym $x_k = a + kH$ dla $k = 0, \dots, N$. Na każdym podprzedziale stosujemy kwadraturę prostą.



Rysunek 6: Graficzna interpretacja złożonej metody trapezów: niebieska linia to wykres funkcji podcałkowej, czerwona linia to wykres przybliżających ją wielomianów interpolacyjnych stopnia co najwyżej 1 opartych na węzłach x_{k-1} i x_k , gdzie $k = 1, 2, \dots, N$.

Złożony wzór trapezów uzyskamy ze wzoru prostego, stosując go dla każdego z podprzedziałów $[x_{k-1}, x_k]$, gdzie $k = 1, 2, \dots, N$ i sumując uzyskane przybliżenia

$$S(f) = \sum_{k=1}^N \frac{x_k - x_{k-1}}{2} (f(x_k) + f(x_{k-1})).$$

Po przekształceniu:

$$S(f) = \frac{H}{2} \left(f(a) + f(b) + 2 \sum_{k=1}^{N-1} f(a + kH) \right).$$

W implementacji lepiej jest stosować ten drugi wzór, ponieważ unikamy dwukrotnego obliczania wartości funkcji w tym samym punkcie. W pewnych językach (np. w Matlabie) można zaimplementować kwadratury tego typu nie obliczając sumy (w sposób jawny). Jak?

Błąd złożonej kwadratury trapezów jest równy

$$E(f) = -\frac{1}{12} H^2 (b - a) f''(\mu_1),$$

dla pewnego $\mu_1 \in (a, b)$.

4.4.2 Złożona kwadratura Simpsona

Złożony wzór Simpsona ma postać:

$$S(f) = \sum_{k=1}^N \frac{H}{6} \left(f(x_{k-1}) + 4f\left(x_{k-1} + \frac{H}{2}\right) + f(x_k) \right).$$

Po przekształceniu:


$$S(f) = \frac{H}{6} \left(f(a) + f(b) + 2 \sum_{k=1}^{N-1} f(a + kH) + 4 \sum_{k=0}^{N-1} f\left(a + kH + \frac{H}{2}\right) \right).$$

Błąd złożonej kwadratury Simpsona jest równy

$$E(f) = -\frac{1}{180 \cdot 2^4} H^4 (b-a) f^{(4)}(\mu_2),$$

dla pewnego $\mu_2 \in (a, b)$.

4.4.3 Złożona kwadratura prostokątów



Rysunek 7: Graficzna interpretacja złożonej metody prostokątów (z węzłem środkowym): niebieska linia to wykres funkcji podcałkowej, czerwona linia to wykres przybliżających ją wielomianów interpolacyjnych stopnia 0 opartych na węzłach $x_{k-1} + \frac{H}{2}$, gdzie $k = 1, 2, \dots, N$.

Złożony wzór prostokątów ma postać:

$$S(f) = \sum_{k=1}^N (x_k - x_{k-1}) f\left(\frac{x_k + x_{k-1}}{2}\right).$$

Po przekształceniu:

$$S(f) = H \sum_{k=1}^N f\left(\frac{x_k + x_{k-1}}{2}\right).$$

Błąd złożonej kwadratury prostokątów (z węzłem środkowym) jest równy

$$E(f) = \frac{1}{24} H^2 (b-a) f''(\mu_3),$$

dla pewnego $\mu_3 \in (a, b)$.

Uwaga 4.5. *Oszacowanie błędu kwadratury prostokątów z węzłem środkowym jest LEP-SZE niż kwadratury trapezów.*

4.4.4 Złożona kwadratura Newtona

Do wyprowadzenia samodzielnie.

4.5 Zmiana przedziału całkowania

W literaturze często można znaleźć kwadratury określone na przedziale $[-1, 1]$ lub $[0, 1]$. Co zrobić, aby wykorzystać taką kwadraturę na dowolnym przedziale $[a, b]$? W przypadku kwadratur Newtona-Cotesa problem ten raczej nie występuje (zwykle są one od razu definiowane na dowolnym przedziale, tak, jak w poprzednim podrozdziale), ale dotyczy innych często używanych kwadratur, na przykład kwadratur Gaussa.

Aby sobie w takiej sytuacji poradzić, można dokonać zamiany zmiennych w całce. Załóżmy, że dla

$$s(x) = \frac{(b-a)x + ad - bc}{d - c}$$

mamy

$$\int_a^b f(x) dx = \frac{b-a}{d-c} \int_c^d f(s(x)) dx.$$

Oznacza to, że mając kwadraturę,

$$\sum_{k=0}^n A_k f(x_k) \approx \int_c^d f(x) dx,$$

przybliżającą całkę na przedziale $[c, d]$, możemy łatwo zmodyfikować tę kwadraturę, tak, aby przybliżała całkę na innym przedziale:

$$\int_a^b f(x) dx \approx \frac{b-a}{d-c} \sum_{k=0}^n A_k f\left(\frac{(b-a)x_k + ad - bc}{d-c}\right).$$

W szczególności, gdy $[c, d] = [0, 1]$, to

$$\int_a^b f(x) dx \approx (b-a) \sum_{k=0}^n A_k f((b-a)x_k + a),$$

a gdy $[c, d] = [-1, 1]$, to

$$\int_a^b f(x) dx \approx \frac{b-a}{2} \sum_{k=0}^n A_k f\left(\frac{b-a}{2}x_k + \frac{a+b}{2}\right).$$

4.6 Metoda Romberga

Niech T_N oznacza przybliżoną wartość całki (4.1) obliczoną za pomocą złożonej kwadratury trapezów z podziałem przedziału całkowania na N podprzedziałów, a E_{T_N} niech oznacza błąd tego przybliżenia.

Błąd ten można wyrazić jako:

$$E_{T_N}(f) = I(f) - T_N(f) = \sum_{k=1}^{\infty} \frac{B_{2k}}{(2k)!} H^{2k} (f^{(2k-1)}(a) - f^{(2k-1)}(b)), \quad (4.4)$$

gdzie B_k ($k = 2, 4, \dots$) są tak zwanymi *liczbami Bernoulliego*. Uzasadnienie powyższego wzoru wykracza poza zakres tego przedmiotu. Na potrzeby naszego wykładu wystarczy

wiedzieć, że B_k są pewnymi stałymi. Istotne dla nas w tym momencie w tym wzorze jest to, że zawiera wyłącznie parzyste potęgi H . Na tym opiera się metoda Romberga. Jej istotą jest zastosowanie tzw. ekstrapolacji Richardsona.

Zdefiniujmy

$$T_{i,0}(f) = T_{2^i}(f), \quad i = 0, 1, \dots \quad (4.5)$$

Na podstawie (4.4), możemy zapisać

$$I(f) - T_{i,0}(f) = \sum_{k=1}^{\infty} c_{2k} H^{2k} = c_2 H^2 + c_4 H^4 + c_6 H^6 + \dots, \quad (4.6)$$

gdzie $H = 2^{-i}(b-a)$, a $c_2, c_4, \dots$ są pewnymi stałymi. Zauważmy, że jeśli $i > 0$, to

$$I(f) - T_{i-1,0}(f) = \sum_{k=1}^{\infty} c_{2k} (2H)^{2k} = 4c_2 H^2 + 16c_4 H^4 + 64c_6 H^6 + \dots \quad (4.7)$$

Zdefiniujmy

$$T_{i,1}(f) = \frac{4T_{i,0}(f) - T_{i-1,0}(f)}{3}, \quad i = 1, 2, \dots \quad (4.8)$$

Z zależności (4.6), (4.7) i (4.8) otrzymujemy

$$I(f) - T_{i,1}(f) = d_4 H^4 + d_6 H^6 + \dots$$

gdzie $d_4, d_6, \dots$ są pewnymi stałymi. Ogólnie, jeśli przyjmiemy

$$T_{i,k}(f) = \frac{4^k T_{i,k-1}(f) - T_{i-1,k-1}(f)}{4^k - 1}, \quad k > 0, \quad i = k, k+1, \dots,$$

i założymy, że funkcja f posiada w $[a, b]$ pochodne dostatecznie wysokiego rzędu, otrzymamy tablicę (zwaną *tablicą Romberga*) zawierającą przybliżone wartości całki (4.1):

$$\begin{array}{cccc} T_{0,0} & & & \\ T_{1,0} & T_{1,1} & & \\ T_{2,0} & T_{2,1} & T_{2,2} & \\ \vdots & \vdots & \vdots & \ddots \end{array}$$

Przybliżenia te mają następujące własności:

- $T_{i,0}(f) = \frac{1}{2}T_{i-1,0}(f) + \frac{1}{2}P_{2^{i-1}}(f)$ dla $i > 0$, gdzie $P_N(f)$ oznacza złożoną kwadraturę prostokątów (z węzłem środkowym) przy podziale przedziału całkowania na N podprzedziałów (zależność ta przydaje się przy tworzeniu pierwszej kolumny tablicy Romberga),
- $T_{i,1}(f) = S_{2^{i-1}}(f)$ dla $i > 0$, gdzie $S_N(f)$ oznacza złożoną kwadraturę Simpsona przy podziale przedziału całkowania na N podprzedziałów (to tylko taka ciekawostka),
- $|I(f) - T_{i,k}(f)| = \mathcal{O}(h^{2k+2}) = \mathcal{O}(4^{-i(k+1)})$ **przy założeniu, że** $f \in C^{2k+2}[a, b]$,

- $I(p) = T_{i,k}(p)$ dla każdego wielomianu $p \in \Pi_{2k+1}$.

Porównajmy teraz w praktyce złożoną kwadraturę trapezów, prostokątów (z węzłem środkowym), Simpsona, Romberga i Gaussa-Legendre’a.

Przykład 4.1. Rozważmy całkę:

$$I(f) = \int_0^1 x \sin(3\pi x^2) dx = 0.10610329539459689051258917558\dots$$

Jeśli będziemy chcieli uzyskać przybliżenie wartości powyższej całki z błędem bezwzględnym mniejszym niż 10^{-13} , to stosując złożoną kwadraturę trapezów będziemy musieli obliczyć wartość funkcji podcałkowej w ponad 4000000 punktów: $|I(f) - T_{4000000}(f)| \simeq 1.05 \cdot 10^{-13}$, gdzie $T_N(f)$ oznacza wynik uzyskany złożoną kwadraturą trapezów przy podziale przedziału całkowania na N podprzedziałów.

Jeśli zastosujemy złożoną kwadraturę prostokątów (z węzłem środkowym), to wartość funkcji podcałkowej trzeba będzie obliczyć prawie 3000000 razy. W tym przypadku: $|I(f) - P_{3000000}(f)| \simeq 9.16 \cdot 10^{-14}$, gdzie $P_N(f)$ oznacza wynik uzyskany złożoną kwadraturą prostokątów (z węzłem środkowym) przy podziale przedziału całkowania na N podprzedziałów.

W przypadku złożonej kwadratury Simpsona będziemy potrzebować około 4400 wartości funkcji podcałkowej: $|I(f) - S_{2200}(f)| \simeq 9.75 \cdot 10^{-14}$, gdzie $S_N(f)$ oznacza wynik uzyskany złożoną kwadraturą Simpsona przy podziale przedziału całkowania na N podprzedziałów. Dla metody Romberga mamy $|I(f) - T_{8,8}(f)| \simeq 1.04 \cdot 10^{-15}$, co oznacza, że w zupełności wystarcza 257 obliczeń wartości funkcji.

Jeśli do tej całki zastosujemy kwadraturę Gaussa-Legendre’a G_{15} (prostą, opartą na 16 węzłach), otrzymamy $|I(f) - G_{15}(f)| \simeq 4.50 \cdot 10^{-14}$.

Dodatkowa lektura: podrozdziały 7.2 i 7.5 z pozycji [1].

Literatura

- [1] D.Kincaid, W.Cheney: Analiza numeryczna, WNT 2005;
- [2] J. i M. Jankowscy (M.Dryja): Przegląd metod i algorytmów numerycznych cz. 1 i 2, WNT, Warszawa 1988;
- [3] Z.Fortuna, B.Macukow, J.Wąsowski: Metody numeryczne, WNT, Warszawa 2006;
- [4] A.Kiełbasiński, H.Schwetlick: Numeryczna algebra liniowa, WNT, Warszawa 1994;
- [5] G.Dahlquist, A.Björck: Metody numeryczne, PWN, Warszawa 1987;
- [6] J.Stoer, R.Bulirsch: Wstęp do analizy numerycznej, PWN, Warszawa 1987;
- [7] Praca zbiorowa pod red. J.Wąsowskiego: Ćwiczenia laboratoryjne z metod numerycznych, OWPW, Warszawa 2002;
- [8] Y.Saad: Iterative Methods for Sparse Linear Systems, SIAM, 1996;
- [9] M.Bollhöfer, V.Mehrmann: Numerische Mathematik, Eine projektorientierte Einführung für Ingenieure, Mathematiker und Naturwissenschaftler, Vieweg Verlag, Brunswik, 2004.
- [10] W.Werner: Polynomial Interpolation: Lagrange versus Newton, Mathematics of Computation 43, no. 167 (1984): 205–17.